MERBench MER2023 多模态情感识别复现实验报告

情感计算课程作业

2026 年 10 月

目录

1 研究背景和问题定义 **2**

2 论文实验范围和本次复现范围 **2**

2.1 MER-MULTI 论文结果行统计 2

2.2 本地实验配置统计 3

3 MERBench 方法和数据流程 **3**

4 特征和模型 **3**

4.1 官方预提取特征 3

4.2 官方 Attention 融合基线 4

4.3 本地门控残差 Attention 改进 4

4.4 类别加权改进 5

5 实验环境和运行设置 **5**

6 评价指标 **6**

7 论文结果与本地复现结果 **6**

7.1 结果分析 6

7.2 Attention 多随机种子稳定性 6

8 单模态、多模态和消融实验 **7**

9 算法改进和改进结果 **7**

9.1 类别加权改进 7

9.2 门控残差 Attention 8

10 误差分析 **8**

11 复现产物和运行方法 **9**

12 复现限制和未完成部分 **10**

13 结论 **10**

14 参考文献 **10**

课程：情感计算

姓名：_____ 学号：_____

选题：MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition

作者：Zheng Lian 等

实验日期：2026 年 10 月

1 研究背景和问题定义

多模态情感识别需要同时利用语音、文本和视觉信息，预测样本的离散情绪类别以及连续情绪维度。不同研究往往使用不同的数据划分、特征提取器、融合模型和评价指标，因此即使报告了相似名称的结果，也不一定能够直接比较。MERBench 的目标是在统一数据、特征、训练和评价流程下比较多种多模态情感识别方法，并分析特征选择、融合策略、跨语料库迁移、噪声鲁棒性和预训练等因素。

本文定义的主要任务为：给定一个中文视频片段的音频特征 x^a、文本特征 x^t 和视觉特征 x^v，预测六分类情绪标签 y^e 以及连续 valence 标签 y^v。本次作业的主测试集为 MER-MULTI，分类标签为 neutral、angry、happy、sad、worried、surprise。

本复现严格锁定 MERBench，不使用 FER2013、FER+ 或其他数据集替代 MER-MULTI，也没有更换成其他论文。

2 论文实验范围和本次复现范围

论文完整的 MERBench 实验族包括单模态特征比较、多模态融合、跨语料库实验、标点鲁棒性、加性噪声鲁棒性、是否需要预训练，以及是否需要下游微调等内容。本次实验优先完成老师要求的 MER2023/MER-MULTI 核心部分：单模态基线、融合基线、结构改进和模态消融。

2.1 MER-MULTI 论文结果行统计

以下统计只针对本项目整理的 MER-MULTI 参考结果文件，不代表论文全部实验族的总数量。

论文表格	内容	结果行数	本地直接复现
Table II	high/medium 单模态	6	3
Table III	两种官方多模态特征组合	2	1
Table IX	五种融合模型的 high/medium 结果	10	5
Table X	Top-k 特征选择	6	0
合计	论文参考表中的 MER-MULTI 结果	**24**	**9**

因此，本地严格对应论文结果行的覆盖率为 $9/24 = 37.5\%$。已经完成的 9 行包括 high 特征的三个单模态结果、一个 high 多模态特征组合结果，以及 Attention、LMF、MISA、TFN、MulT 五个 high 融合结果。Table IX 的 high 融合结果已经完成 $5/5$。

2.2 本地实验配置统计

本地结果总表中目前有 13 个命名实验配置：5 个论文融合基线、3 个单模态实验、2 个改进实验和 3 个模态缺失消融实验。Attention 另使用固定超参运行了 seed 2026、2027、2028 三次统计，因此实际保存了额外的多 seed 运行结果。每个配置还分别记录交叉验证、MER-MULTI、MER-NOISE 和 MER-SEMI 的结果，这些测试划分输出不应被重复计数为新的独立模型。

3 MERBench 方法和数据流程

本地复现流程如下：

1. 使用官方 `label-6way.npz` 和转写文件读取 MER2023 标签及数据划分。
2. 使用作者提供的预提取音频、文本和视觉特征，避免在 8GB 显存设备上重新提取大型模型特征。
3. 将三种模态特征输入官方融合模型或本地结构改进模型。
4. 同时优化离散情绪分类和 valence 回归任务。
5. 在 Train&Val 上进行五折交叉验证，并在 MER-MULTI、MER-NOISE、MER-SEMI 上测试。
6. 保存每次运行的配置、训练日志、每折最佳模型、预测结果、分类报告和混淆矩阵。

MER2023 的本地划分如下。该划分与论文数据统计一致：Train&Val 有 3373 个样本，MER-MULTI 有 411 个样本，MER-NOISE 有 412 个样本，MER-SEMI 有 834 个带离散标签样本；MER-SEMI 还包含大量未标注样本。

split	含义	样本数	本地使用方式
train_corpus	Train&Val	3373	五折训练和验证
test1_corpus	MER-MULTI	411	主要对照测试集
test2_corpus	MER-NOISE	412	噪声鲁棒性测试输出
test3_corpus	MER-SEMI	834	半监督相关测试输出

MER-MULTI 的六类标签分布为：neutral 88、angry 105、happy 93、sad 50、worried 57、surprise 18。该分布不均衡，尤其 `surprise` 样本较少，因此报告同时使用 WAF 和 UAR 观察分类性能。

4 特征和模型

4.1 官方预提取特征

本地可验证读取的 high UTT 特征为：

模态	特征	本地目录	单样本维度
audio	chinese HuBERT large	`chinese-hubert-large-UTT`	1024
text	Baichuan-13B-Base	`Baichuan-13B-Base-UTT`	5120

模态	特征	本地目录	单样本维度
visual	CLIP ViT-L/14	`clip-vit-large-patch14-UTT`	768

MulT 正式实验使用对应 FRA 特征：`chinese-hubert-large-FRA`、`Baichuan-13B-Base-FRA` 和 `clip-vit-large-patch14-FRA`。UTT 表示句子级特征，FRA 表示用于帧级对齐序列融合的特征。

4.2 官方 Attention 融合基线

对于每种模态，官方 Attention 模型先使用独立编码器得到统一隐空间表示：

$$h_a = E_a(x^a), \quad h_t = E_t(x^t), \quad h_v = E_v(x^v).$$

UTT 特征使用 MLP 编码器，FRA 特征使用 LSTM 编码器。三个模态表示拼接后输入注意力网络，得到三个模态的融合分数：

$$s = W_2\phi(W_1[h_a; h_t; h_v]),$$

然后按官方实现将三个隐向量进行加权融合，并通过两个输出头分别预测离散情绪和 valence：

$$\hat{y}^e = F_e(z), \quad \hat{y}^v = F_v(z).$$

训练目标为分类损失和回归损失之和，官方模型选择指标为：

$$M = WAF - 0.25 \times MSE.$$

4.3 本地门控残差 Attention 改进

为了实现模型结构层面的改进，本文在官方 Attention 的三路编码器和双任务输出头基础上增加门控融合模块。设原始注意力分数为 s，首先计算归一化注意力权重：

$$\alpha = softmax(s).$$

再由拼接特征估计每个样本的模态可靠性：

$$r = \sigma(G([h_a; h_t; h_v])).$$

将两者相乘后重新归一化：

$$w_m = \frac{\alpha_m r_m}{\sum_j \alpha_j r_j + \epsilon}.$$

最终融合表示为：

$$z = \sum_{m \in \{a,t,v\}} w_m h_m + \beta R([h_a; h_t; h_v]),$$

其中 R 是轻量 MLP 残差支路，β 为可学习缩放参数，初始化为 0.1。该设计有两个目的：一是根据样本内容动态降低不可靠模态的影响，二是保留简单加权和不能表达的跨模态交互。该改进只增加融合层参数，不重新训练特征提取器，适合当前显存条件。

4.4 类别加权改进

对于类别加权版本，分类损失使用基于训练集类别频数反比得到的 balanced weight：

$$w_c = \frac{N}{C \cdot n_c},$$

其中 N 为训练样本数，C 为类别数，n_c 为第 c 类样本数。回归损失仍使用普通 MSE。该实验用于检验类别不均衡修正的效果，与门控残差结构改进分开运行。

5 实验环境和运行设置

项目	设置
操作系统	Windows PowerShell
GPU	NVIDIA GeForce RTX 4060 Laptop GPU
显存	约 8GB
Python	3.12.3
PyTorch	2.6.0+cu124
CUDA	12.4
NumPy	1.26.4
scikit-learn	1.7.2
pandas	2.2.2
默认随机种子	2026
UTT batch size	32
MulT FRA batch size	16
训练轮数	100
交叉验证	Train&Val 五折

本地环境与作者仓库中的旧版环境并不完全一致，因此本报告将结果称为“基于官方特征和官方代码结构的本地复现值”，不把它们写成论文原始报告值。

6 评价指标

- **WAF**：weighted F1，按类别样本数加权的 F1。
- **ACC**：分类准确率。
- **UAR**：macro recall，即各类别召回率的平均值，更关注少数类。
- **MSE**：valence 回归均方误差，越低越好。
- **模型选择指标**：$WAF - 0.25 \times MSE$。

MER-SEMI 的 valence 标签为 `-10` 占位值，因此本地结果中只报告其分类指标，不将其 MSE 与 MER-MULTI 或 MER-NOISE 的 MSE 比较。

7 论文结果与本地复现结果

下表主要列出论文 Table II、Table III 和 Table IX 中与当前 high 特征直接对应的结果。论文值来自本地保存的 `results/official_mer2023_mermulti.csv`，本地值来自 seed 2026 的真实运行结果。论文 WAF 和本地 WAF/ACC/UAR 均以百分数表示。

实验	来源	论文 WAF	论文 MSE	本地 WAF	本地 ACC	本地 UAR	本地 MSE
Audio HUBERT-large	Table II	69.91	0.97	68.59	68.61	63.56	0.9345
Text Baichuan-13B	Table II	62.54	1.63	60.68	60.83	55.36	1.6614
Visual CLIP-large	Table II	62.69	1.12	60.99	62.29	51.87	1.1297
Attention high	Table IX / Table III	83.03	0.62	80.45	80.78	75.78	0.6253
LMF high	Table IX	83.44	-	80.02	80.05	74.91	0.7023
MISA high stable	Table IX	82.42	-	80.00	80.05	75.11	0.6591
TFN high	Table IX	82.52	-	80.49	80.78	75.35	0.6934
MulT high FRA	Table IX	82.94	-	80.39	80.54	77.62	0.8183

7.1 结果分析

1. 三个单模态本地结果与论文值处于同一数量级，audio 结果最接近论文 WAF。
2. 多模态融合明显优于单模态，说明音频、文本和视觉之间存在互补信息。
3. 五个 high 融合基线的本地 WAF 约为 80%，比论文报告值低约 2.4 到 3.4 个百分点。
4. Attention 的本地 MSE 0.6253 与论文 Table III high 特征组合的 0.62 接近，但分类 WAF 低于论文值。
5. 可能的差异来源包括论文多次运行均值和标准差、本地使用单 seed、官方随机超参搜索没有完全复刻、MISA 使用了稳定超参，以及 PyTorch/CUDA 版本不同。

7.2 Attention 多随机种子稳定性

固定 `configs/attention_stable.yaml`，在 MER-MULTI 上运行三个 seed：

seed	WAF	ACC	UAR	MSE
2026	80.45	80.78	75.78	0.6253
2027	83.06	82.97	80.19	0.6311
2028	82.71	82.73	78.66	0.6157
均值 ± 标准差	**82.07 ± 1.15**	**82.16 ± 0.98**	**78.21 ± 1.83**	**0.6240 ± 0.0064**

Attention 的 WAF 标准差为 1.15 个百分点，UAR 标准差为 1.83 个百分点，说明单次 seed 结果存在一定波动。报告中的主要基线对照仍使用 seed 2026，三 seed 均值作为稳定性补充，不替代论文报告值。

8 单模态、多模态和消融实验

以下为 MER-MULTI/test1 的本地结果：

类型	实验	WAF	ACC	UAR	MSE
单模态	audio only	68.59	68.61	63.56	0.9345
单模态	text only	60.68	60.83	55.36	1.6614
单模态	visual only	60.99	62.29	51.87	1.1297
多模态	Attention high	80.45	80.78	75.78	0.6253
多模态	LMF high	80.02	80.05	74.91	0.7023
多模态	MISA high stable	80.00	80.05	75.11	0.6591
多模态	TFN high	80.49	80.78	75.35	0.6934
多模态	MulT high FRA	80.39	80.54	77.62	0.8183
消融	Drop audio	74.54	74.45	70.15	0.9129
消融	Drop text	76.74	76.89	72.31	0.6763
消融	Drop visual	75.22	75.18	71.08	0.8886

Drop audio 后 WAF 比完整 Attention 下降 5.91 个百分点，Drop visual 后下降 5.23 个百分点，Drop text 后下降 3.71 个百分点。在当前特征和模型设置下，音频和视觉对离散分类的贡献更明显。Drop text 的 MSE 仍为 0.6763，说明 valence 回归可能仍较依赖音频和视觉信息。

9 算法改进和改进结果

9.1 类别加权改进

类别加权版本的 MER-MULTI 结果如下：

实验	WAF	ACC	UAR	MSE
Attention high	80.45	80.78	75.78	0.6253
Attention + class weight	81.56	81.51	78.45	0.6327

相对于原始 Attention，WAF 提升 1.11 个百分点，ACC 提升 0.73 个百分点，UAR 提升 2.67 个百分点，MSE 增加 0.0074。该结果说明类别加权对于不均衡六分类任务有效，尤其改善宏平均召回；但分类权重调整不保证 valence 回归误差同时下降。

9.2 门控残差 Attention

实验	WAF	ACC	UAR	MSE
Attention high	80.45	80.78	75.78	0.6253
Gated residual Attention	81.21	81.27	77.74	0.6369

相对于原始 Attention，门控残差结构的 WAF 提升 0.76 个百分点，ACC 提升 0.49 个百分点，UAR 提升 1.96 个百分点，MSE 增加 0.0116。它优于原始 Attention，但 WAF 和 UAR 略低于类别加权版本。因此，本实验支持“门控残差结构有正向效果”，但不支持“门控残差结构在所有指标上优于类别加权”。

两种改进的侧重点不同：类别加权修改训练损失，针对类别不均衡；门控残差 Attention 修改融合结构，针对样本级模态可靠性和跨模态交互。为区分各自贡献，本轮没有直接叠加两种改进。

10 误差分析

以 `Attention + class weight` 在 MER-MULTI 上的混淆矩阵为例：

真实类别 \ 预测类别	neutral	angry	happy	sad	worried	surprise
neutral	68	3	7	4	6	0
angry	8	88	2	4	2	1
happy	8	0	84	0	0	1
sad	2	2	1	44	1	0
worried	10	0	0	7	40	0
surprise	1	1	2	1	2	11

主要现象如下：

- `happy` 和 `angry` 的识别相对稳定，主要因为测试样本数量较多且情绪线索较明显。
- `surprise` 只有 18 个测试样本，类别加权后正确数为 11，召回率约为 61.11%，仍然容易受单个样本影响。
- `worried` 容易被预测为 `neutral` 或 `sad`，说明低唤醒负向情绪之间存在边界模糊。
- 类别加权后少数类表现有所改善，但整体 MSE 没有同步下降，体现了分类和 valence 回归之间的任务权衡。

11 复现产物和运行方法

官方代码和本地复现代码位于：

`references/MERTools/MERBench`
`reproduction/MERBench`

本地复现代码、配置、结果表和本报告源文件已公开在 GitHub: https://github.com/cai-jj21/merbench-mer2023-reproduction

重要产物如下：

内容	路径
LaTeX 报告源文件	`reports/merbench_report.tex`
报告 PDF	`reports/merbench_report.pdf`
GitHub 代码仓库	https://github.com/cai-jj21/merbench-mer2023-reproduction
数据准备说明	`DATA_PREP.md`
数据核验状态	`DATA_STATUS.md`
运行 README	`README.md`
运行脚本	`scripts/run_merbench_experiments.ps1`
官方结果参考表	`results/official_mer2023_mermulti.csv`
本地结果总表	`results/local_reproduction_summary.csv`
多 seed 汇总	`results/attention_multiseed_summary.csv`
改进结果	`results/gated_residual_attention_high_seed2026_formal/gated_residual_attention_high_seed2026_formal.csv`
改进模型代码	`patches/toolkit/models/gated_attention.py`
日志和 checkpoint	`runs/`

从工作区根目录执行数据核验。为便于排版，命令中的脚本路径使用变量：

```
$run = ".\reproduction\MERBench\scripts\run_merbench_experiments.ps1"
$verify = ".\reproduction\MERBench\scripts\verify_mer2023_features.py"
python $verify `
  --data-root ".\reproduction\MERBench\data\mer2023-dataset-process" `
  --features chinese-hubert-large-UTT Baichuan-13B-Base-UTT `
  clip-vit-large-patch14-UTT
```

运行官方融合基线：

```
powershell -File $run -Stage attention
powershell -File $run -Stage lmf
powershell -File $run -Stage misa
powershell -File $run -Stage tfn
powershell -File $run -Stage mult_resume -Epochs 100 -BatchSize 16
```

运行改进、消融和汇总：

```
powershell -File $run -Stage improved -Epochs 100 -BatchSize 32
powershell -File $run -Stage classweight -Epochs 100 -BatchSize 32
powershell -File $run -Stage ablation -Epochs 100 -BatchSize 32
python .\reproduction\MERBench\scripts\build_summary_tables.py `
  --root .\reproduction\MERBench
```

12 复现限制和未完成部分

1. 当前 `feature.zip` 只包含 high UTT/FRA 特征目录，没有 medium/low 特征池，因此无法完成论文 Table II、Table III、Table IX 中对应的 medium 结果，也无法完成 Table X 的 Top-k 特征选择。
2. 本地对 Attention 完成了三个 seed 的固定超参统计，LMF、MISA、TFN、MulT 等其他正式基线主要使用 seed 2026，不能冒充论文的多次运行均值和标准差。
3. 官方默认 MISA 随机超参在本机出现 NaN，正式报告使用稳定超参版本，并保留默认运行失败日志。
4. 本地没有重新提取 CLIP、HuBERT 和 Baichuan 特征，因此复现范围是“基于作者官方预提取特征的融合训练与评测”。
5. 本轮没有完成论文的跨语料库、标点鲁棒性、原始加性噪声生成流程、预训练和下游微调等完整实验族。MER-NOISE 和 MER-SEMI 的本地测试输出已经保存，但不能据此宣称完整复现论文全部鲁棒性和半监督实验。
6. 本地环境为 Windows、Python 3.12、PyTorch 2.6，而作者 README 中的环境较旧，版本差异可能影响数值结果。

因此，本项目的准确表述是：**完成 MERBench/MER2023 核心融合实验的本地复现，以及一组结构改进和消融实验；尚未完成论文全部实验族的严格复现。**

13 结论

本复现使用官方 MERBench 代码结构和官方 MER2023 预提取特征，在 RTX 4060 Laptop 8GB 环境下完成了可运行、可追溯的 MER-MULTI 核心实验。单模态实验表明，单独使用音频、文本或视觉的性能明显低于多模态融合；五种融合基线均表现出多模态互补优势。模态缺失消融显示，音频和视觉缺失对分类性能的影响大于文本缺失。

改进方面，类别加权版本取得了当前最高的 WAF 81.56 和 UAR 78.45；门控残差 Attention 取得 WAF 81.21 和 UAR 77.74，相比原始 Attention 有稳定的正向提升。两种改进分别从类别不均衡和模态可靠性两个角度改善模型，结果具有可解释性，但仍需要更多随机种子和完整特征池实验验证泛化性。

本地严格对应论文 MER-MULTI 参考结果完成 9/24 项，已满足本课程作业要求的论文基线、改进实验和消融实验要求；medium/low、Top-k、跨语料库及其他论文实验族明确列为尚未完成部分。

14 参考文献

1. Zheng Lian, Licai Sun, Yong Ren, Hao Gu, Haiyang Sun, Lan Chen, Bin Liu, Jianhua Tao. *MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition*. arXiv:2401.03429, 2024. https://arxiv.org/html/2401.03429
2. MERBench 官方代码仓库：https://github.com/zeroQiaoba/MERTools/tree/master/MERBench
3. MERBench 官方 README 中的 MER2023 预提取特征入口：https://pan.baidu.com/s/1l2yrWG3wXHjdRljAk32fPQ；提取码：`uds2`