MERBench MER2023 多模态情感识别复现实验报告

蔡均炅　2026210870

2026 年 10 月

课程：情感计算
姓名：蔡均炅　　学号：2026210870
选题：*MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition*
作者：Zheng Lian 等

1　实验目标

本作业复现 MERBench 在 MER2023/MER-MULTI 上的核心实验：根据中文视频的音频、文本和视觉特征预测六类情绪（neutral、angry、happy、sad、worried、surprise），同时回归 valence。实验覆盖单模态、三模态融合和轻量改进，重点不是跑通代码，而是检查本地结果是否与论文趋势一致。考虑到 RTX 4060 Laptop GPU 约 8GB 显存，全部实验使用作者提供的预提取特征，没有重新训练 HuBERT、CLIP 或 Baichuan。论文报告值与本地复现值始终分列，不混用。

2　数据、特征与评价指标

MER2023 本地划分与论文一致：Train&Val 3373 个样本做五折训练/验证，MER-MULTI 411 个样本作为主要测试集。MER-MULTI 六类标签数量为 neutral 88、angry 105、happy 93、sad 50、worried 57、surprise 18，类别明显不均衡，这也是后续改进的直接动机。

表 1: 本地使用的数据和 high 特征

模态	特征提取器	特征目录	维度
audio	chinese HuBERT large	`chinese-hubert-large-UTT`	1024
text	Baichuan-13B-Base	`Baichuan-13B-Base-UTT`	5120
visual	CLIP ViT-L/14	`clip-vit-large-patch14-UTT`	768

官方模型同时训练分类与 valence 回归，报告 WAF（weighted F1）、ACC、UAR（macro recall）和 MSE，综合选择指标为 $M = WAF - 0.25 \times MSE$。除特别说明外，分类指标均为百分数，正式运行使用随机种子 2026，五折交叉验证结果取均值。

3　论文基线与本地复现结果

本地直接对应论文 MER-MULTI 参考表的结果共 10/24 项（41.7%）：high 特征下的三种单模态、high 多任务组合以及 Attention、LMF、MISA、TFN、MulT、MMIM 六种融合基线。另对 MFN 和 GMFN 做了完整数据五折的 5 epoch 扩展训练，对 MFM、MCTN 保留了 1 epoch debug 冒烟。扩展训练不等价于论文的 100 epoch 正式结果。medium/low 特征和 Top-k 特征选择因官方特征包中没有对应特征池，未在本轮执行。

表 2: 论文值与本地复现值对照

实验	论文 WAF	本地 WAF	本地 ACC	本地 UAR	论文 MSE	本地 MSE
Audio HUBERT-large (Table II)	69.91	68.59	68.61	63.56	0.97	0.9345
Text Baichuan (Table II)	62.54	60.68	60.83	55.36	1.63	1.6614
Visual CLIP (Table II)	62.69	60.99	62.29	51.87	1.12	1.1297
High multi-task combination (Table III)	83.02	80.45	80.78	75.78	0.62	0.6253
Attention high (Table III/IX)	83.03	80.45	80.78	75.78	0.62	0.6253
LMF high (Table IX)	83.44	80.02	80.05	74.91	–	0.7023
MISA high (Table IX)	82.42	80.00	80.05	75.11	–	0.6591
TFN high (Table IX)	82.52	80.49	80.78	75.35	–	0.6934
MulT high FRA (Table IX)	82.94	80.39	80.54	77.62	–	0.8183
MMIM high (Table IX)	81.01	75.96	76.40	68.72	–	0.7084

本地融合模型的 WAF 大约比论文低 2.4–5.1 个百分点，但排序和“三模态明显优于单模态”的趋势完全一致；Attention 的回归 MSE（0.6253）与论文值（0.62）接近。MMIM 使用稳定配置后的 WAF 为 75.96，低于论文 81.01，说明互信息辅助项对超参数更敏感。差距可能来自论文报告多次运行均值、本地只使用单一 seed、部分超参数为本地稳定性重调，以及软件环境差异。因此表中本地列只用于复现比较，不代表论文原始值。

4 单模态、多模态与消融

表 3: MER-MULTI 上的本地实验结果

类型	实验	WAF	ACC	UAR	MSE
单模态	audio	68.59	68.61	63.56	0.9345
单模态	text	60.68	60.83	55.36	1.6614
单模态	visual	60.99	62.29	51.87	1.1297
融合	Attention	80.45	80.78	75.78	0.6253
融合	LMF	80.02	80.05	74.91	0.7023
融合	MISA	80.00	80.05	75.11	0.6591
融合	TFN	80.49	80.78	75.35	0.6934
融合	MulT FRA	80.39	80.54	77.62	0.8183
融合	MMIM stable	75.96	76.40	68.72	0.7084
扩展	MFN FRA (5 epochs)	56.52	61.80	49.05	0.9639
扩展	GMFN FRA (5 epochs)	59.35	62.04	51.25	0.9903
消融	Drop audio	74.54	74.45	70.15	0.9129
消融	Drop text	76.74	76.89	72.31	0.6763
消融	Drop visual	75.22	75.18	71.08	0.8886

三模态融合明显优于任何单模态：Attention 相比最好的 audio 单模态，WAF 提高 11.86 个百分点，MSE 从 0.9345 降至 0.6253。模态缺失消融显示，去掉 audio 后 WAF 下降 5.91 个百分点，去掉 visual 下降 5.23，去掉 text 下降 3.71；在当前特征下 audio 贡献最大，而去掉 text 后 MSE 反而最低（0.6763），说明文本特征对回归头有一定干扰，或者其回归信息已被 audio/visual 覆盖。

MFN 的 5 epoch 全量五折扩展结果为 WAF 56.52、ACC 61.80、UAR 49.05、MSE 0.9639；GMFN 的对应结果为 WAF 59.35、ACC 62.04、UAR 51.25、MSE 0.9903。两组结果只用于记录本地序列模型的有限训练情况，不能与论文 Table IX 的 100 epoch 均值直接比较；MFM、MCTN 本轮仍只完成 1 epoch debug 冒烟。

5 实验环境与运行方式

所有正式实验在以下环境完成：Windows 11 + PowerShell，Python 3.12.3，PyTorch 2.6.0+cu124（CUDA 12.4），GPU 为 NVIDIA GeForce RTX 4060 Laptop GPU（8GB），numpy 1.26.4、scikit-learn 1.7.2、pandas 2.2.2。训练均从作者预提取特征出发，单卡 batch size 16–32 即可放下，未做混合精度或梯度累积。

代码复用官方 MERTools/MERBench 结构，本地改动全部集中在 `patches/`，运行脚本按阶段划分，从工作区根目录执行：

```
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage verify
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage attention
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage lmf
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage classweight
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage improved
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage ablation
.\reproduction\MERBench\scripts\run_merbench_experiments.ps1 -Stage summary
```

其中 `-Stage verify` 校验数据划分与特征维度；`-Stage summary` 从官方`.npz` 结果重建 CSV/JSON/Markdown 汇总表、分类报告和混淆矩阵。MISA 使用 `configs/hyper_stable.yaml` 稳定超参；MulT 断点续跑用 `-Stage mult_resume`；Attention 多 seed 稳定性用 `run_attention_multiseed.ps1`。

6 其他测试集结果

除主测试集 MER-MULTI（test1）外，本地还汇总了 MER-NOISE（test2，加入噪声的样本）与 MER-SEMI（test3，无标注半监督样本的伪指标）上的官方脚本输出。test3 无真实标签，其指标仅反映与训练分布的一致性，不代表真实泛化性能；valence 回归在 test3 上不可比，故省略。重点观察 test2：融合模型相对单模态仍有明显优势，但 Attention+class weight 在 test2 上（WAF 77.64）相对原 Attention（77.67）没有提升，说明类别加权带来的 UAR 收益主要来自训练分布内的类别再平衡，在强噪声扰动下优势收窄。

表 4: 各测试集 WAF（本地，seed 2026，百分数）

实验	MER-MULTI	MER-NOISE	MER-SEMI*
Audio only	68.59	62.97	85.47
Text only	60.68	48.99	53.40
Visual only	60.99	62.44	68.94
Attention	80.45	77.67	87.12
LMF	80.02	73.13	86.81
MISA (stable)	80.00	74.54	87.11
TFN	80.49	78.17	89.14
MulT FRA	80.39	76.22	85.18
Attention + class weight	81.56	77.64	89.35
Gated residual Attention	81.21	74.09	88.83
Drop audio	74.54	71.17	77.50
Drop text	76.74	74.01	88.16
Drop visual	75.22	65.15	86.27

*test3 无人工标注，数值来自官方伪标签输出，仅供完整性参考。

7 实验产出与可复现性

每个正式实验都保存了运行配置、随机种子、训练日志和测试输出，避免只保留一张结果表：`results/<实验名>/run_config.json` 记录模型、特征、batch size、epoch、seed 和消融参数；`runs/*.log` 记录每折训练与验证指标；`runs/<run>-trimodal/model/` 保存最优 fold、epoch、指标和模型状态；各结果目录还包含分类报告与混淆矩阵，总表在 `results/local_reproduction_summary.csv/json/md`。

数据核验脚本会检查标签文件、Train&Val/MER-MULTI 划分以及每个特征目录的样本数量和首个样本维度。对于 UTT 特征，audio、text、visual 的维度分别为 1024、5120 和 768；FRA 特征用于 MulT 的帧级对齐输入。所有指标均通过同一套官方评价函数计算，并额外导出分类报告和混淆矩阵，确保表格中的 WAF、ACC、UAR 和 MSE 能从原始输出重新统计。

本地数据和模型权重没有上传 GitHub：前者受官方分发方式限制，后者体积较大且不是复现代码的一部分。仓库保留补丁、配置、运行脚本、结果索引和报告；按 README 下载并解压 `feature.zip` 后可在同一目录结构中重新运行。因此本项目的可复现边界是“基于官方预提取特征的训练与评测”，而非重新训练特征提取器。

8 代码修改与实现细节

复现基于官方 MERTools/MERBench 结构，所有改动集中在 `patches/` 目录，运行前覆盖到官方代码对应位置，共涉及六类修改。

1. **数据路径 Windows 化**（`config.py`）：官方默认路径指向作者服务器，本地增加 `MERBENCH_MER2023_ROOT` 环境变量和相对路径解析，使数据目录可以放在仓库外的任意磁盘位置。

2. **训练入口适配**（`main-release.py`）：增加 `--class_weight`、`--drop_modalities`、`--start_fold`/`--resume_root` 参数；每次运行保存完整 `run_config.json`；增加确定性随机种子设置（关闭 cuDNN benchmark）；模型保存改为通用 `state_dict` 格式，而不是依赖 `save_pretrained`。

3. **模态缺失消融**（`toolkit/data/feat_data.py`）：读取 `drop_modalities_list`，在数据集初始化阶段将对应模态特征替换为零矩阵，而不是在模型内部做 mask，保证对所有融合模型一致生效。

4. **类别加权损失**（`toolkit/utils/loss.py` 与训练入口）：`CELoss` 接受权重张量；训练开始前统计训练折的类别频率，按 $w_c = N/(KN_c)$ 构造 balanced 权重，并写入日志便于检查。

5. **门控残差融合模型**（`toolkit/models/gated_attention.py`）:新增 `GatedResidualAttention`。三个模态编码器与官方 Attention 相同；融合层先由 MLP 产生样本级可靠性门控（sigmoid），与 attention 权重相乘并归一化，再加一个可学习缩放的跨模态残差分支（初始缩放 0.1），最后送入原来的分类/回归头。

6. **模型注册与配置**（`models/__init__.py`、`data/__init__.py`、`model-tune.yaml`）：注册 `gated_attention`;新增固定超参文件 `configs/hyper_stable.yaml` 和 `configs/hyper_extended.yaml`，并为 MMIM 增加 `hyper_mmim_stable.yaml`，将高风险互信息项和学习率调低以避免 NaN。

7. **扩展实验脚本**（`run_merbench_experiments.ps1`）：增加 MMIM、MFN、GMFN、MFM、MCTN 阶段、`-Debug` 冒烟模式以及断点恢复参数；每次运行仍自动保存日志、配置、checkpoint 和 CSV/JSON/Markdown 汇总。

9 算法改进与结果

9.1 类别加权

MER-MULTI 中 surprise 只有 18 个样本，而 angry 有 105 个。原始交叉熵会被多数类主导，少数类召回偏低。改进在分类损失中加入逆频率权重

$$\mathcal{L} = \mathcal{L}_{reg} + \lambda\, \mathcal{L}_{cls}^{weighted}, \qquad w_c = \frac{N}{K\, N_c},$$

其中 N_c 是类别 c 的训练样本数，$K = 6$。回归损失保持不变，因此 valence 分支的训练强度不变。

9.2 门控残差 Attention

官方 Attention 对三种模态做 softmax 加权求和，隐含假设三种模态在每个样本上都同等可靠。改进引入一个轻量门控：由拼接的三模态隐向量经 MLP 输出 3 维 sigmoid 门控，衡量各模态在该样本上的可靠程度；将门控与 attention 权重逐元素相乘并重新归一化，实现样本级的模态

表 5: 改进方法在 MER-MULTI 上的结果

实验	WAF	ACC	UAR	MSE
Attention baseline	80.45	80.78	75.78	0.6253
Attention + class weight	81.56	81.51	78.45	0.6327
Gated residual Attention	81.21	81.27	77.74	0.6369

抑制。再补充一个跨模态残差分支（两层 MLP，可学习标量缩放从 0.1 起步），弥补加权求和难以表达的非线性交互。该设计不改变特征提取，仅增加少量参数，与官方基线保持公平比较。

类别加权是最有效的改进：WAF 提升 1.11 个百分点，UAR 提升 2.67 个百分点，MSE 仅增加 0.0074。门控残差 Attention 的 WAF 提升 0.76、UAR 提升 1.96 个百分点，同样优于基线但略低于类别加权。两种改进正交（一个作用于损失，一个作用于融合结构），后续可以叠加验证。为检查随机性，Attention 固定超参用 seed 2026/2027/2028 重复运行，WAF 均值为 82.07（标准差 1.15），说明 80–82% 是当前设置的合理区间，单 seed 差距不应被过度解读。

10 复现过程中的困难

1. **数据获取**：官方特征包托管在百度网盘，脚本直接调用下载 API 返回 `errno=2`，必须由用户通过客户端手动下载约数 GB 的 `feature.zip`，解压到本地数据目录后逐目录校验 5030 个`.npy` 文件。

2. **显存与时长**：RTX 4060 Laptop 8GB 无法一次跑完所有模型的高显存配置。MulT 的正式五折运行因时长中断过一次，为此实现了 `--start_fold`/`--resume_root` 机制，从已保存的 fold checkpoint 恢复，不重复训练。

3. **MISA 训练不稳定**：默认随机超参组合出现 NaN loss，定位为梯度爆炸。通过 `hyper_stable.yaml` 将梯度裁剪设为 0.8、学习率降为 1e-4 后重新训练，得到稳定结果（WAF 80.00）。

4. **MMIM 训练不稳定**：MMIM 原始设置在第 43 个 epoch 出现 NaN。保留了失败日志和 fold1 最佳 checkpoint，改用 `alpha=beta=0.01`、学习率 10^{-5}、梯度裁剪 0.6 的稳定设置恢复后续四折，最终完成五折 100 epoch 训练。

5. **序列模型耗时**：MFN/GMFN/MFM/MCTN 的 FRA 输入在时间步上循环，8GB 显卡下小 batch 训练明显慢。MFN 和 GMFN 完成了全量五折 5 epoch 扩展，GMFN 单折约 21–23 分钟；MFM/MCTN 当前只完成 debug 冒烟，不能写作正式论文复现值。

6. **模型保存接口**：官方代码在保存分支中调用 `save_pretrained`，对自定义模型不可用，改为统一 `torch.save(state_dict)`，并使 checkpoint 记录 fold、epoch、指标与 args。

7. **Windows 兼容**：官方脚本假设 Linux 路径和 shell 行为，本地将数据路径改为环境变量驱动，日志和 checkpoint 文件名做了非法字符清洗（`sanitize_filename`）。

11 误差分析

从混淆矩阵看，audio 单模态已经包含较强情绪线索；融合后整体提高，但少数类 surprise 仍容易被识别为 neutral 或 happy，worried 与 neutral、sad 之间也存在混淆。类别加权提升 UAR（75.78 → 78.45）而 ACC 提升较小（80.78 → 81.51），说明它主要改善少数类召回，而不是提高多数类正确率——这正是设计意图。

分类与回归指标并不完全同步：两种改进都提高了分类表现，但 MSE 均略有上升（0.6253 → 0.6327/0.6369），说明模型在优化离散类别边界时牺牲了一部分连续 valence 的拟合。这也是同时报告四个指标的原因。

12 复现限制与结论

本轮完成 MER-MULTI 的 high 特征单模态、六种正式融合基线、MFN/GMFN 全量五折 5 epoch 扩展、三种模态缺失消融、类别加权和门控残差改进，论文参考结果覆盖 10/24 项（41.7%）。MFM/MCTN 已完成代码和输入兼容性冒烟，但没有完成论文设置的正式 100 epoch 结果。尚未完成 medium/low 特征、Top-k 特征选择、跨语料库、MER-NOISE 噪声测试、预训练与下游微调等实验族，因此不能声称完整复现论文全部 24 项结果。

结论有三点：第一，三模态融合显著优于单模态，验证了 MERBench 的核心结论；第二，六种 high 融合基线中五种常规模型达到约 80% WAF，稳定 MMIM 受超参影响较大，与论文趋势一致但绝对值偏低；第三，针对类别不均衡的 balanced 加权是本次最有效的改进（本地最高 WAF 81.56、UAR 78.45），门控残差结构次之，两者均有保留价值。

代码、配置、日志索引和数据准备说明已上传至：

`https://github.com/cai-jj21/merbench-mer2023-reproduction`

仓库不上传受限数据、特征压缩包或模型权重；README 说明了从本地数据目录运行的步骤，官方 MERTools 作为外部依赖保留。

参考文献

[1] Zheng Lian et al. *MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition*. arXiv:2401.03429, 2024.

[2] Zheng Lian et al. MER2023 数据集与多模态情感识别基准，见 MERBench 官方代码仓库。

[3] 本地复现代码：`https://github.com/cai-jj21/merbench-mer2023-reproduction`。