MERBench MER2023 多模态情感识别复现实验报告

情感计算课程作业

2026 年 10 月

课程：情感计算
姓名：_____ 学号：_____
选题：*MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition*
作者：Zheng Lian 等

1 实验目标

本作业严格复现 MERBench 在 MER2023/MER-MULTI 上的核心实验。任务是根据中文视频的音频、文本和视觉特征，预测六类情绪：neutral、angry、happy、sad、worried 和 surprise，同时回归 valence。实验重点是比较单模态、三模态融合模型，并在官方 Attention 基线上加入轻量改进。

考虑到设备为 RTX 4060 Laptop GPU（约 8GB 显存），本实验直接使用作者提供的预提取特征，没有重新训练 HuBERT、CLIP 或大型语言模型。论文报告值和本地运行值始终分开列出；本地结果是使用官方特征、官方代码结构和本地随机种子得到的复现值，不冒充论文原始结果。

2 数据、特征与评价指标

MER2023 的本地划分与论文统计一致：Train&Val 有 3373 个样本，MER-MULTI 有 411 个样本。本报告以 MER-MULTI 为主要测试集。其六类标签数量分别为 neutral 88、angry 105、happy 93、sad 50、worried 57、surprise 18，类别明显不均衡。

表 1: 本地使用的数据和 high 特征

模态	特征提取器	特征目录	维度
audio	chinese HuBERT large	`chinese-hubert-large-UTT`	1024
text	Baichuan-13B-Base	`Baichuan-13B-Base-UTT`	5120
visual	CLIP ViT-L/14	`clip-vit-large-patch14-UTT`	768

官方模型同时进行分类和 valence 回归。报告分类的 WAF（weighted F1）、ACC 和 UAR（macro recall），以及回归 MSE。论文和本地代码使用的综合选择指标为

$$M = WAF - 0.25 \times MSE.$$

除特别说明外，表中分类指标均为百分数，所有正式结果使用随机种子 2026。

3 论文基线与本地复现结果

本地直接对应论文 MER-MULTI 参考表的结果共有 9/24 项，覆盖率为 37.5%。其中 high 特征下的三种单模态、Table III 的 high 多任务组合、Attention、LMF、MISA、TFN 和 MulT 五种融合结果均已完成；medium/low 特征和 Top-k 特征选择没有在本轮执行。

表 2: 论文值与本地复现值对照

实验	论文 WAF	本地 WAF	本地 ACC	本地 UAR	论文 MSE	本地 MSE
Audio HUBERT-large (Table II)	69.91	68.59	68.61	63.56	0.97	0.9345
Text Baichuan (Table II)	62.54	60.68	60.83	55.36	1.63	1.6614
Visual CLIP (Table II)	62.69	60.99	62.29	51.87	1.12	1.1297
High multi-task combination (Table III)	83.02	80.45	80.78	75.78	0.62	0.6253
Attention high (Table III/IX)	83.03	80.45	80.78	75.78	0.62	0.6253
LMF high (Table IX)	83.44	80.02	80.05	74.91	–	0.7023
MISA high (Table IX)	82.42	80.00	80.05	75.11	–	0.6591
TFN high (Table IX)	82.52	80.49	80.78	75.35	–	0.6934
MulT high FRA (Table IX)	82.94	80.39	80.54	77.62	–	0.8183

本地结果与论文在同一数量级，但五个融合模型的 WAF 大约低 2.4–3.4 个百分点。Attention 的回归 MSE 为 0.6253，与论文的 0.62 接近；分类差距可能来自论文多次运行均值、本地只使用单一 seed、超参数搜索范围不同以及软件环境差异。因此，表中的本地列用于复现和比较，不能直接当作论文原值。

4 单模态、多模态与消融

表 3: MER-MULTI 上的本地实验结果

类型	实验	WAF	ACC	UAR	MSE
单模态	audio	68.59	68.61	63.56	0.9345
单模态	text	60.68	60.83	55.36	1.6614
单模态	visual	60.99	62.29	51.87	1.1297
融合	Attention	80.45	80.78	75.78	0.6253
融合	LMF	80.02	80.05	74.91	0.7023
融合	MISA	80.00	80.05	75.11	0.6591
融合	TFN	80.49	80.78	75.35	0.6934
融合	MulT FRA	80.39	80.54	77.62	0.8183
消融	Drop audio	74.54	74.45	70.15	0.9129
消融	Drop text	76.74	76.89	72.31	0.6763
消融	Drop visual	75.22	75.18	71.08	0.8886

三模态融合明显优于单模态：Attention 相比最好的单模态 audio，WAF 提高 11.86 个百分点，UAR 提高 12.22 个百分点，MSE 从 0.9345 降至 0.6253。模态缺失实验表明，去掉 audio 后 WAF 下降 5.91 个百分点，去掉 visual 后下降 5.23 个百分点，去掉 text 后下降 3.71 个百分点；在当前特征和划分下，audio 对整体识别最重要，text 的回归贡献也较明显。

5 算法改进与结果

本次改进围绕类别不均衡和模态可靠性展开，均不增加新的特征提取开销。

5.1 类别加权

对分类交叉熵加入按训练集类别频率计算的逆频率权重，使少数类在损失中具有更大影响：

$$\mathcal{L} = \mathcal{L}_{reg} + \lambda \mathcal{L}_{cls}^{weighted}, \qquad w_c = \frac{N}{K N_c}.$$

其中 N_c 是类别 c 的训练样本数，$K = 6$。

5.2 门控残差 Attention

在官方 Attention 融合后增加一个轻量门控残差模块。模型根据三种模态的隐向量计算样本级门控权重，再将门控融合结果与原 Attention 表示相加，最后送入分类和回归头。该设计允许模型在不同样本上降低不可靠模态的影响，同时保持官方融合结构，便于公平比较。

表 4: 改进方法在 MER-MULTI 上的结果

实验	WAF	ACC	UAR	MSE
Attention baseline	80.45	80.78	75.78	0.6253
Attention + class weight	81.56	81.51	78.45	0.6327
Gated residual Attention	81.21	81.27	77.74	0.6369

类别加权是本轮最有效的改进：相对 Attention，WAF 提升 1.11 个百分点，ACC 提升 0.73 个百分点，UAR 提升 2.67 个百分点；MSE 仅增加 0.0074。门控残差 Attention 的 WAF 提升 0.76 个百分点，UAR 提升 1.96 个百分点，也优于原始基线，但略低于类别加权版本。说明处理少数类对本数据集的收益比增加融合结构更稳定。

为检查随机性，Attention 固定超参使用 seed 2026、2027、2028 重复运行，WAF 均值为 82.07，标准差为 1.15；UAR 均值为 78.21，标准差为 1.83。这组均值用于稳定性补充，不替代上表的单 seed 对照。

6 简要误差分析

从混淆矩阵和分类报告看，audio 单模态已经包含较强的情绪线索；融合后整体性能提高，但少数类 surprise 仍然容易被识别为 neutral 或 happy。worried 与 neutral、sad 之间也存在混淆，说明仅依赖句子级特征时，细粒度负面情绪的边界仍不够清晰。类别加权提高了 UAR，表明它主要改善了少数类召回，而不是单纯提高多数类准确率。

分类指标和回归指标并不完全同步。类别加权和门控残差都提高了分类表现，但 MSE 略有上升，说明模型在优化离散类别边界时牺牲了一部分连续 valence 的拟合。这也是本实验同时报告 WAF、ACC、UAR 和 MSE 的原因。

7 复现限制与结论

本轮完成了 MER-MULTI 的 high 特征单模态、五种正式融合基线、三种模态缺失消融、类别加权和门控残差改进，论文参考结果逐项覆盖为 9/24。尚未完成 medium/low 特征、Top-k 特征选择、跨语料库、完整噪声生成、预训练与下游微调等实验族，因此不能声称完整复现论文全部 24 项结果。

结论可以概括为三点：第一，audio、text、visual 三模态融合显著优于单模态；第二，官方 Attention、LMF、MISA、TFN 和 MulT 在本地均达到约 80% WAF，结果与论文趋势一致；第三，针对 MER-MULTI 类别不均衡的类别加权取得最高本地结果 WAF 81.56、UAR 78.45，是本次最值得保留的改进。

代码、配置、日志索引和数据准备说明已上传至：

`https://github.com/cai-jj21/merbench-mer2023-reproduction`

仓库不上传受限数据、特征压缩包或模型权重；README 说明了从本地数据目录运行的步骤，官方 MERTools 作为外部依赖保留。

参考文献

[1] Zheng Lian et al. *MERBench: A Unified Evaluation Benchmark for Multimodal Emotion Recognition*. arXiv:2401.03429, 2024.

[2] Zheng Lian et al. MER2023 数据集与多模态情感识别基准，见 MERBench 官方代码仓库。

[3] 本地复现代码：`https://github.com/cai-jj21/merbench-mer2023-reproduction`。